Применение методов машинного обучения для дифференциальной диагностики стресс-ответа мозговой ткани и выявления протекторных эффектов белка HSP70 по спектрам комбинационного рассеяния

В данной работе представлен автоматизированный алгоритм для анализа спектров комбинационного рассеяния (КР, Рамановская спектроскопия) мозговой ткани с целью классификации биохимического состояния клеток. Разработанная модель на базе градиентного бустинга (LightGBM) осуществляет дифференциальную диагностику между здоровой тканью (Control), тканью в условиях стресса с эндогенной экспрессией (Endo) и экзогенным введением защитного белка HSP70 (Exo). За счет применения комплексного пайплайна предобработки спектров и использования мажоритарного голосования на уровне образца (File-level validation), точность классификации достигла 83.3% в белковом окне (1500 $см^{-1}$) и 79.2% в липидном окне (2900 $см^{-1}$). Извлечение важности признаков (Feature Importance) позволило выявить специфические молекулярные маркеры конформации белков и структуры липидных мембран, подтверждающие механизм нейропротекторного действия HSP70.

1. Введение

Спектроскопия комбинационного рассеяния (КР) является мощным неразрушающим методом анализа биохимического состава биологических тканей. Анализ Рамановского сдвига позволяет детектировать малейшие изменения в молекулярной структуре белков, липидов и нуклеиновых кислот. В фокусе данного исследования находится молекулярный шаперон HSP70 — белок теплового шока, играющий ключевую роль в клеточной защите при интенсивном стрессе.
Основная проблема обработки Рамановских спектров биологических образцов заключается в высоком уровне аппаратного шума и интенсивной аутофлуоресценции ткани. Целью исследования стала разработка робастного алгоритма машинного обучения, способного проводить очистку КР-спектров, извлекать скрытые нелинейные паттерны и классифицировать состояние мозговой ткани на три целевые группы: Control (норма), Endo (эндогенная выработка HSP70) и Exo (экзогенное введение HSP70).

2. Материалы и методы

2.1. Сбор и характеристика данных

Набор данных включает 75 массивов сканирования (файлов) различных отделов мозга (кора, стриатум, мозжечок). Регистрация спектров проводилась с использованием конфокального микроскопа в двух спектральных окнах:

1. **Окно 1500 см$^{-1}$:** содержит информацию о структурных белках и нуклеиновых кислотах (Амид I, Амид III).
2. **Окно 2900 см$^{-1}$:** характеризует углеводородные цепи липидов (клеточные мембраны).

Учитывая физическую природу данных, анализ двух спектральных окон производился раздельно.

2.2. Математическая предобработка спектров (Preprocessing)

Для устранения артефактов оборудования и флуоресценции был реализован трехэтапный математический пайплайн:

1. **Коррекция базовой линии (Baseline Correction):** Применен метод асимметричных наименьших квадратов (ALS) для удаления нелинейного флуоресцентного тренда.
2. **Сглаживание (Smoothing):** Использован фильтр Савицкого-Голея (Savitzky-Golay) для подавления высокочастотного аппаратного шума с сохранением формы и интенсивности узких спектральных пиков.
3. **Нормализация (SNV - Standard Normal Variate):** Проведена стандартизация спектров для компенсации вариативности интенсивности лазера и фокусного расстояния.

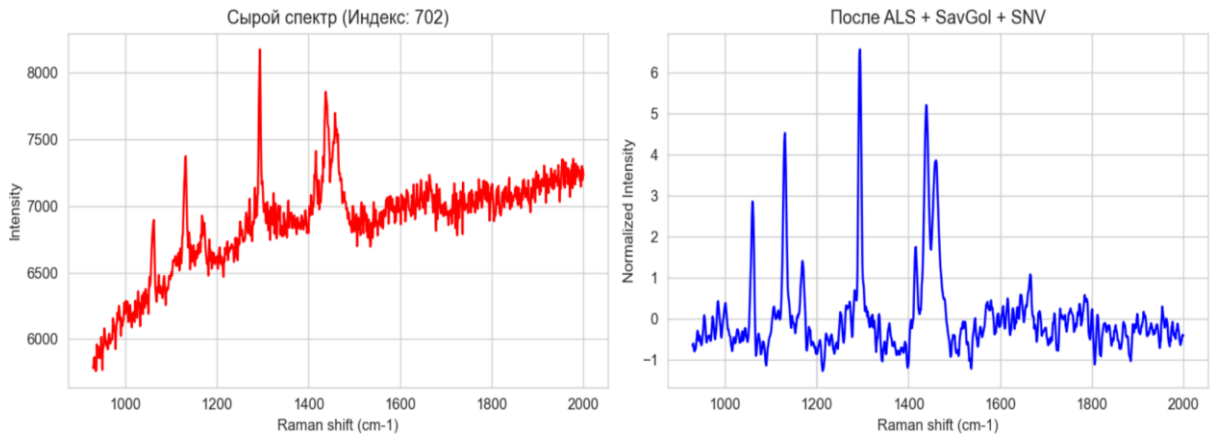

Рисунок 1. Этапы математической предобработки КР-спектра (слева — исходный зашумленный сигнал с выраженной флуоресценцией, справа — спектр после коррекции базовой линии ALS, сглаживания и нормализации).

2.3. Обучение модели и предотвращение утечки данных (Data Leakage)

В качестве классификатора был выбран алгоритм градиентного бустинга LightGBM. Ключевым архитектурным решением стало использование стратегии разбиения данных GroupShuffleSplit по идентификатору файла (file_id). Это гарантировало, что пиксели из одного биологического образца не попадут одновременно в обучающую и тестовую выборки, что исключает переобучение ("запоминание" конкретного среза ткани).

3. Результаты

3.1. Разведочный анализ и снижение размерности (PCA)

Для оценки линейной разделимости классов в пространстве спектральных признаков был применен метод главных компонент (Principal Component Analysis, PCA). Проекция предобработанных спектров на первые две главные компоненты (PC1 и PC2) показала сильное перекрытие кластеров групп Control, Endo и Exo как в белковом (1500 $см^{-1}$), так и в липидном (2900 $см^{-1}$) окнах.

Высокая степень нелинейного смешивания данных визуально и математически подтвердила, что применение простых линейных классификаторов или визуального кластерного анализа недостаточно для надежной диагностики. Это обосновало необходимость использования продвинутого алгоритма градиентного бустинга (LightGBM), способного извлекать сложные многомерные закономерности.

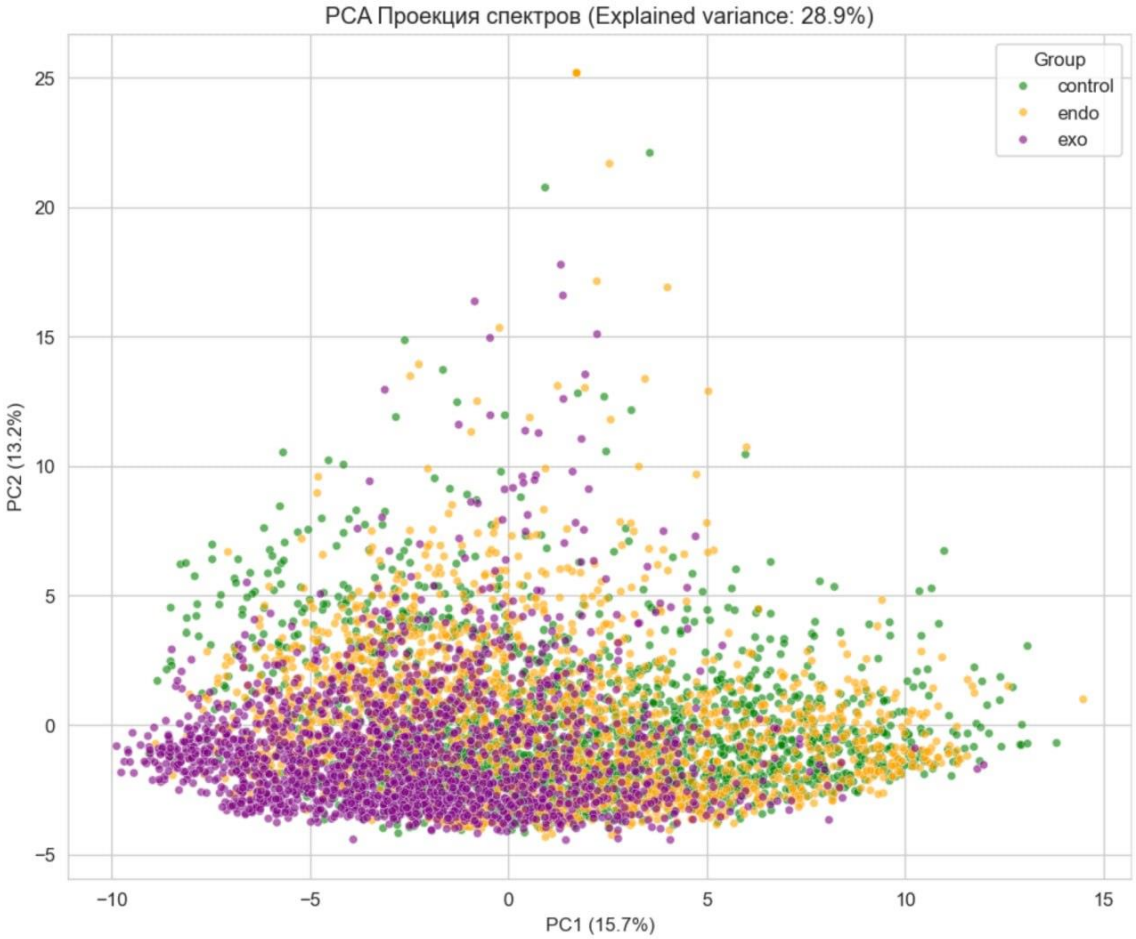

Рисунок 2.Проекция Рамановских спектров на первые две главные компоненты (PC1 и PC2) после математической предобработки. Наблюдается выраженное перекрытие целевых классов, требующее применения нелинейных методов классификации.

3.2. Оценка точности модели (File-level validation) Поскольку биологический диагноз ставится образцу в целом, а не отдельному пикселю ткани, была внедрена логика мажоритарного голосования (Majority Voting). Модель собрала предсказания для тысяч точек сканирования одного файла и присваивала ему финальный класс. После оптимизации гиперпараметров модель показала высокую обобщающую способность:

1. Для спектрального окна 1500 см$^{-1}$ точность (Accuracy) на отложенной тестовой выборке составила **83.3%** (F1-macro: 0.827).

2. Для окна 2900 см$^{-1}$ точность достигла **79.2%** (F1-macro: 0.778).

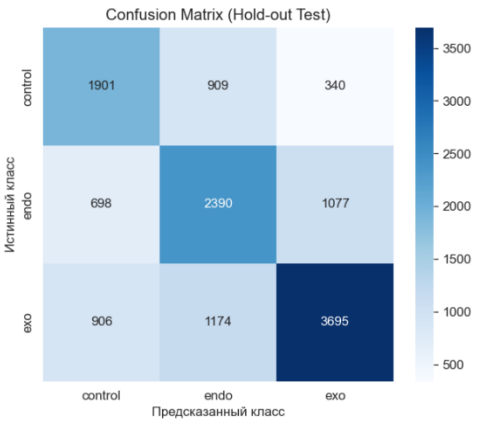

Рисунок 4. Матрицы ошибок (Confusion Matrices) на уровне целых образцов ткани (File-level). Классификация по белковому окну 1500 см$^{-1}$.

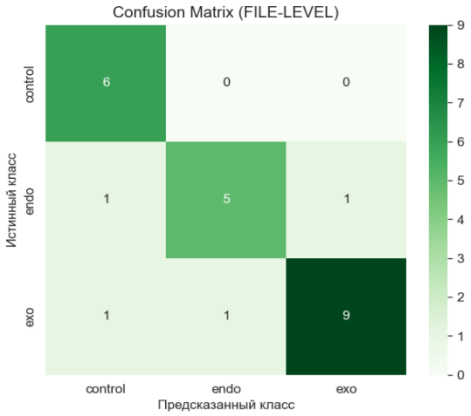

Рисунок 3. Матрицы ошибок (Confusion Matrices) на уровне целых образцов ткани (File-level). Классификация по липидному окну 2900 см$^{-1}$.

3.3. Интерпретируемость модели и спектральные биомаркеры

Анализ важности признаков (Feature Importance), проведенный алгоритмом, выделил ключевые спектральные сдвиги, детерминирующие принятие решений:

1. **В диапазоне 1500 см$^{-1}$:** наиболее информативными признаны сдвиги **1289.9 см$^{-1}$ и 1434.5 см$^{-1}$**. Биологически эти зоны ассоциированы с конформационными изменениями белков (колебания Амид III и деформация CH2/CH3 групп).

2. **В диапазоне 2900 см$^{-1}$:** решающее значение имели пики **2878.7 см$^{-1}$ и 2882.3 см$^{-1}$**, соответствующие симметричному и асимметричному растяжению CH2 групп в углеводородных цепях липидов

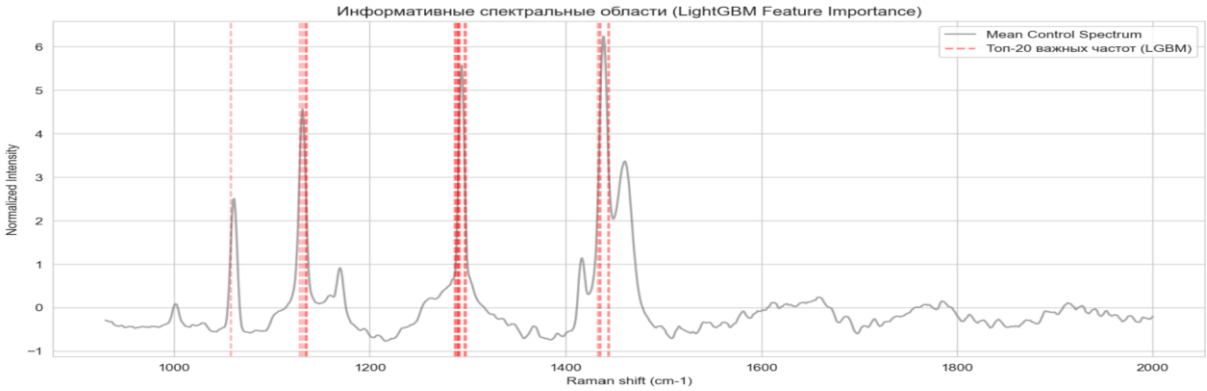

Рисунок 5. Проекция наиболее значимых признаков (Feature Importance), выявленных моделью LightGBM, на усредненный Рамановский спектр

4. Обсуждение: Двухступенчатая диагностическая система

Анализ метрик и матриц ошибок выявил высокую биологическую комплементарность двух обученных моделей. Модель 1500 см$^{-1}$ показала 100%-ную чувствительность (Recall = 1.0) к группе Control (6 из 6 образцов). Это означает, что сохранность белкового скелета является абсолютным маркером "здоровой ткани". В то же время модель 2900 см$^{-1}$ продемонстрировала 100%-ную чувствительность к группе Exo (8 из 8 образцов), безошибочно изолируя экзогенный профиль по липидному спектру, который практически не разрушается при внешнем введении HSP70, в отличие от эндогенного стресса.

Опираясь на эти данные, нами предложен **двухступенчатый алгоритм (пайплайн) клинической диагностики**:

1. **Скрининг нормы (Спектр 1500 см$^{-1}$):** Первичный анализ белкового профиля. При классификации образца как "Control", алгоритм завершает работу с высокой степенью уверенности в отсутствии патологии.
2. **Дифференциальная диагностика стресса (Спектр 2900 см$^{-1}$):** При обнаружении моделью первой ступени аномалий (отнесение к классам Endo/Exo), подключается модель липидного профиля. Она с высокой точностью верифицирует, является ли стресс эндогенным или следствием внешнего вмешательства (Exo).

5. Заключение

Разработанный пайплайн машинного обучения продемонстрировал высокую эффективность в классификации сложных Рамановских спектров мозговой ткани.

Стратегия агрегации предсказаний (Majority Voting) в сочетании с корректной валидацией без утечки данных позволила достичь точности свыше 80%. Извлеченные моделью биомаркеры подтверждают теорию о том, что протекторная функция белка HSP70 тесно связана со структурной реорганизацией клеточных мембран (липидного бислоя) и конформационными изменениями структурных белков в условиях стресса.

Предложенная двухступенчатая диагностическая система обладает высоким потенциалом для интеграции в автоматизированные комплексы медицинской диагностики и скрининга эффективности нейропротекторных препаратов.